

Systematic Review Screening 流程深度研究報告

以 LLM / multi-agent 與傳統創新 workflow 為雙主線，並結合 NLP / Speech 場景與 NLP_PRISMA_Reviews 實例分析

版本：超深入版

日期：2026-04-12

讀者情境：Automatic Survey Generation / OrionVault / multi-agent screening pipeline

重點：prompt template、criteria、逐篇 paper 精讀、repo 與錯誤分析、可落地工作流建議

文件導覽

點擊下列條目可直接跳至對應章節。本文同時在附錄保留 prompt 原文片段或英文規格化版本，以及逐篇 paper / repo 的來源。

[0. 報告目的與核心結論](#)

[1. 先把 systematic review screening 這件事講清楚](#)

[2. 本報告的檢索與整理方法](#)

[3. Prompt template 家族總覽（中文模板在主文）](#)

[4. LLM / agent 路線逐篇精讀](#)

[4.1 Wang 2024：最簡單的單體 yes/no prompt](#)

[4.2 Akinseloyin 2024：把 criteria 拆成 QA](#)

[4.3 Sanghera 2025：用 prompt 當 decision threshold](#)

[4.4 Cao 2025 / srma：generic prompt templates](#)

[4.5 ReviewCopilot 2025：先抽結構化 evidence，再做決策](#)

[4.6 A4SLR 2025：agentic framework 不只 screening](#)

[4.7 Akinseloyin 2026：multi-agent collaboration](#)

[4.8 2026 新趨勢補充：fine-tuning 與 validation](#)

[5. 傳統但更有創新性的 screening workflow 逐篇精讀](#)

[5.1 Gartlehner 2020：單人審核風險的基準線](#)

[5.2 Nama 2021：依排除理由決定是否複核](#)

[5.3 Noel-Storr 2021 : crowd + ML hybrid](#)

[5.4 Pham 2021 : semi-automated workflow](#)

[5.5 Shemilt 2022 : living evidence 的 recall-calibrated classifier](#)

[5.6 ASReview LAB v2 2025 : shared model + crowd of experts](#)

[6. 把醫學 SR 的 criteria 轉譯到 NLP / Speech](#)

[7. NLP_PRISMA_Reviews 深入案例分析：為什麼 GPT-5.4 單 reviewer 還是會差](#)

[8. 給 OrionVault / multi-agent survey generation pipeline 的建議流程](#)

[9. 結論](#)

[附錄 A. Prompt 原文片段與英文規格化模板](#)

[附錄 B. 各 paper 的 criteria 與領域摘要](#)

[附錄 C. F1 / F2 / F3 重算說明](#)

[參考文獻](#)

0. 報告目的與核心結論

第一，近兩年最有價值的 LLM screening 進展，不是單純把「是否納入」直接丟給一個模型，而是逐步把審核規則拆成可追溯的 criterion、evidence、uncertainty 與 adjudication。從 Wang 2024 的單體 yes/no，到 Akinseloyin 2024/2026 的 question-answering 與 multi-agent aggregation，再到 ReviewCopilot 的 extract-then-decide，以及 A4SLR 的 agentic orchestration，方法演化的共同方向都不是『更像聊天』，而是『更像可稽核流程』。

第二，傳統路線真正有創新價值的重點，不是 reviewer 從單人、雙人、三人機械地加入，而是如何把第二次複核、crowd、active learning 或 ML classifier 放到最能降低 false exclusion 的位置。Nama 2021、Noel-Storr 2021、Pham 2021、Shemilt 2022 與 ASReview v2 共同指出：高效率 workflow 的核心，是把人工注意力集中在高風險邊界案例，而不是平均地花在所有紀錄上。

第三，直接把生醫 SR 的 prompt 或 PICOS 套到 NLP / Speech 往往會失敗。原因不只是領域不同，而是 eligibility signal 的位置與性質不同。NLP / Speech 論文常需要同時判斷 task scope、輸入/輸出 modality、model family、paper type、是否 primary empirical study、以及 evidence 是否真的支持 criteria；這些訊號常不在 abstract，而在方法節、附錄或 benchmark 描述中。

第四，對你自己的 NLP_PRISMA_Reviews 來說，GPT-5.4 單 reviewer baseline 的問題不在模型名字，而在 workflow design。該實驗明確標為 experiment-only baseline；它把複雜 criteria 壓成單一 stage_score，評估時又把 maybe 算進 positive，且全文常被截斷。以 2409.13738 為例，single-reviewer baseline 的 F1 看起來較高，但 current workflow 的 recall 更高，F2 與 F3 反而更好。這正是 SR screening 中『F1 不是唯一指標』的典型案例。

第五，如果目標是把 screening 接進 OrionVault 與 survey generation pipeline，最值得採用的不是單 reviewer classifier，而是『metadata gate + criterion decomposition + evidence extraction + routed full-text review + senior adjudication + audit trail』的多階段設計。Vault 中應保存 criteria 版本、evidence quote、uncertain points、adjudication 理由、以及錯誤分析結果，讓系統能被回顧、修正與迭代。

本報告的使用方式

如果你要把這份內容直接接到 OrionVault / AUTOSR-SDSE，最值得優先讀的章節是第 3 章、第 6 章、第 7 章與第 8 章。第 3 章提供 prompt family；第 6 章把醫學 SR 的 criteria 語言轉譯到 NLP / Speech；第 7 章直接解剖單 reviewer 失敗原因；第 8 章則給出可操作的推薦 workflow。

1. 先把 systematic review screening 這件事講清楚

在 systematic review (SR) 裡，screening 指的是：從大量檢索回來的 citation 中，依照事先寫好的 protocol 與 inclusion / exclusion criteria，決定哪些研究要被保留到下一階段。最常見的實務流程分成兩層：第一層是 title/abstract screening，第二層是 full-text screening。第一層通常是高工作量、低單筆資訊密度；第二層則是低工作量、但每筆需要更高判斷精度。

生醫領域之所以常被拿來做 screening 自動化研究，是因為它的 protocol 與 criteria 相對成熟，像 PICO / PICOS 這種槽位定義很穩定；但這也造成一個常見誤解：大家會以為 screening 只是『看主題有沒有相關』。其實真正的 screening 是依照 criteria 核對 paper 是否同時滿足一組必要條件，這些條件未必都出現在題名或摘要裡。

對 NLP / Speech 來說，criteria 經常不是 Population/Intervention 那種傳統醫學槽位，而是『任務類型、輸入模態、輸出模態、模型家族、是否 primary empirical research、是否真的做了某種 evidence-bearing evaluation』。因此，直接搬醫學 prompt 往往會出錯，因為模型容易把 topical relatedness 當成 eligibility。

術語	在 SR 裡是什麼意思
Systematic Review (SR)	依預先寫好的 protocol，用系統化搜尋、明確的納排條件、標準化評讀與合成方法，回答一個明確研究問題。它不是一般敘述型文獻回顧，而是一個可重現的證據生產流程。
Protocol	正式執行前先寫好的作戰藍圖，通常定義研究問題、資料庫、搜尋式、納排 criteria、screening 流程、資料抽取欄位、風險偏誤評估方法與分析計畫。
PRISMA	Systematic review 的報告準則。最常見的是 PRISMA 2020，規範你該如何透明地報告搜尋、篩選、排除理由與最終納入研究。
Title/Abstract screening	先看題名與摘要做第一輪篩選。這一輪通常追求高 recall，寧願多保留一些 uncertain cases，也不要太早把真正相關文獻排掉。
Full-text screening	對通過第一輪的紀錄取得全文，再依 criteria 做第二輪判定。真正不可逆的 final exclusion 通常應盡量留到這一階段。
Inclusion / Exclusion criteria	決定一篇 paper 能否進入 review 的規則。醫學常寫成 PICO/PICOS；NLP/Speech 更常需要 task、modality、model family、paper type、evidence type 等多維條件。
PICO / PICOS	Population、Intervention、Comparison、Outcome、Study design。醫學介入性 review 常用這組槽位組織 criteria。
DTA review	Diagnostic Test Accuracy review，重點是診斷工具是否準確，criteria 與 intervention review 很不同，常會出現 index test、reference standard 等術語。
Adjudication	當兩位 reviewer 或多個 agent 的判斷不一致時，由 senior reviewer 或規則化整合程序做最後裁決。
Sensitivity / Recall	在所有應該納入的研究中，有多少被成功保留下來。對

	screening 而言通常是最重要的安全指標，因為漏掉 relevant study 的代價很高。
Specificity	在所有應該排除的研究中，有多少被正確排除。高 specificity 可節省工作量，但若一味追求它，常會傷到 recall。
Precision / PPV	模型判成 positive 的那些研究裡，有多少是真的 relevant。對 triage 有用，但若 maybe 仍要人工複核，就不能把 precision 直接等同於實際自動化效益。
F1 / F2 / F3	Precision 與 Recall 的調和平均。F1 對兩者權重相同；F2 與 F3 更強調 recall。在 SR screening 裡，F2 / F3 往往比 F1 更貼近實際風險。
WSS@95	Work Saved over Sampling at 95% recall。在至少保住 95% recall 的條件下，方法能幫你省掉多少人工篩選工作。active learning 與 prioritization 研究很常用這個指標。
MAP	Mean Average Precision，衡量排序品質。當系統先做 prioritization 而不是直接 binary include/exclude 時，MAP 比 F1 更合適。
Active learning / prioritization	先把最可能 relevant 的 records 排到前面，人工標註後再回饋模型，持續重排剩餘紀錄。它重點不是一次做 final decision，而是用排序節省人工。
Liberal accelerated screening	一種快速流程：只要任一 reviewer 傾向保留，就先保留到下一階段；只有明確排除時才淘汰。這能保 recall，但會增加後續工作量。
Living review / living register	不是做完一次就結束，而是持續更新。這時 recall-calibrated classifier 與 workflow automation 的價值特別高。

為什麼這些 jargon 要先講清楚

後面很多 paper 不用 F1，而是用 WSS@95、MAP、priority ranking 或 recall-calibrated classifier。這不是作者偷懶，而是因為它們解的是不同子問題：有些系統負責排序與工作量減少，有些系統負責最終納入決策。若把所有研究都硬壓成同一個 binary F1，反而會誤判方法優劣。

2. 本報告的檢索與整理方法

本報告的文獻與實作調查以 2026-04-12 前可公開取得的論文、期刊頁面、preprint、GitHub repo、以及 repo 內 prompt / results / criteria 檔案為主。對於可能在 2025-2026 間更新的資訊，例如 repo 狀態、最新 paper、當前 results manifest，本報告一律以線上搜尋與 repo 當前公開內容為準。

收錄原則分成兩條線。第一條是 LLM / agent 路線：我只納入真正與 screening workflow 有直接關係的研究，而不是泛泛談 LLM 用於醫學研究的大型綜述。第二條是傳統但更有創新性的流程：重點不是 reviewer 數量，而是有沒有把 verification、crowd、active learning、text mining 或 collaborative ML 放進一個更有效率而又可保 recall 的設計中。

prompt 相關資料再分成三種可信度。A 級是 repo 中直接公開的 prompt，或在論文 / search snippet 中可看到接近完整原文。B 級是方法段足以重建出『規格化模板』，但沒有逐字公開原文。C 級則只有高層方法說明，適合討論 workflow，但不適合聲稱取得 exact prompt。本報告主文中的中文模板會盡量完整，附錄中的英文則依 A/B/C 級分開標示。

F1 的處理也做了嚴格區分。若 paper 已公開 precision 與 recall，或公開足夠的 confusion matrix，我就直接重算 F1；若只有 sensitivity / specificity 且沒有 prevalence 或各 review 的加權細節，我就不硬算『看似精確』但其實不可驗證的 F1。對 ranking / prioritization 型研究，如 MAP、WSS@95 為主的工作，我也不會把它們硬改寫成 F1 paper，因為那會扭曲任務本身。

對你自己的 NLP_PRISMA_Reviews，我不只讀 repo 說明頁，而是直接讀 single-reviewer experiment template、current runtime prompts、criteria JSON、results manifest、以及 single-reviewer 與 current workflow 的 metrics JSON，再用本地統計重新整理全文截斷、正負例計分方式與 F-beta 差異。

3. Prompt template 家族總覽（中文模板在主文）

這一章的目的不是蒐集漂亮 prompt，而是把 screening prompt 的設計哲學分型。對真正的 SR screening 來說，prompt 的核心任務不是生成流暢文字，而是把 eligibility decision 拆成可追溯、可校準、可稽核的判斷過程。

圖 1 SR screening 流程設計的譜系：從 reviewer-count 到可稽核 agentic workflow

這不是單一路徑的替代關係，而是設計重心的位移：越往右，越重視把 criteria、evidence、uncertainty 與 adjudication 明文化。



設計演化的核心問題，不只是『到底要幾個 reviewer』，而是『怎樣把錯誤風險集中在可被人工複核的地方』。

對你的 NLP / Speech 場景而言，最值得借用的是最右側這一欄：把模糊條件拆成可檢核的 criterion，再把 uncertain cases 保留下來，而不是讓單一模型一次做不可逆排除。

圖 1. SR screening workflow taxonomy。圖中把 prompt / workflow 分成五個家族：單體 yes/no、逐條 QA、可校準高召回、先抽結構化 evidence 再做決策、多 agent + senior adjudication。

這張圖不是文獻中的原圖，而是根據本次調查重新整理的 taxonomy。其目的不是描述某一篇 paper，而是把不同 paper 真正做的事放到同一張方法圖譜裡。

3.1 家族 A：單體 yes / no 判斷型 prompt（對應 Wang 2024）

公開程度 / fidelity	A 級。原始樣式可由 Wang 2024 的公開摘要 / 海報片段辨識，模板很短。
適用情境	適合先做極快的高召回初篩基線，或當 ensemble 中的一個弱分類器。它的優點是便宜、易校準；缺點是 criteria 沒有被拆開，因此在邊界型任務上容易把主題相似誤當成符合 eligibility。
常見失敗模式	對 NLP / Speech 最常見的失敗是：把『看起來很相關』誤判成『符合 criteria』；遇到 survey、benchmark、position paper 或 modality 不純的研究時，沒有足夠結構去分辨。

中文模板（可直接改寫）

你是一位 systematic review 的第一輪審核者。

任務：只根據提供的 review 問題與 study 題名/摘要，回答這篇 study 是否應保留到下一階段。

Review topic / inclusion focus :
[在此放入 review 題目或極短 criteria 摘要]

Study :
Title: [title]
Abstract: [abstract]

- 規則：
- (1) 若摘要中出現任何足以支持納入的核心訊號，寧可保留。
 - (2) 若資訊不足，不要自行補完；可偏向保留。
 - (3) 嚴禁使用外部知識。

輸出：只回答 YES 或 NO。

這個模板的價值不在於逐字照抄，而在於它代表了一種決策分解方式。真正移植到 NLP / Speech 時，最重要的是把『criteria 的原子單位』定義清楚，而不是單純把 paper title 改掉。

3.2 家族 B：逐條 criteria 問答型 prompt（對應 Akinseloyin 2024/2026）

公開程度 / fidelity	B 級。論文方法段足以重建 question generation 與 QA judgment 的規格，但未完整公開逐字 prompt。
適用情境	適合 criteria 比較複雜、需要拆成多個可核對條件的場景。這是最值得轉譯到 NLP / Speech 的家族，因為你可以把『topic 是否相關』拆成 task、input modality、output modality、paper type、empirical evidence 等多個子問題。
常見失敗模式	若 criteria 本身含有很長的 OR clause、例外條款或多層依賴關係，question generation 可能漏掉子條件；此外，它本質上較適合 prioritization / ranking，不一定等於 final binary exclusion。

中文模板（可直接改寫）

你是一位 systematic review 的審核者。請先把 selection criteria 轉成最多 5 個互不重複的核對問題；每個問題都必須能直接用題名/摘要中的文字回答。

Selection criteria :
[完整 criteria]

Study :
Title: [title]
Abstract: [abstract]

步驟 1：產生問題
Q1. [核心 eligibility 問題]
Q2. ...
最多 5 題。

步驟 2：逐題作答
對每題只允許輸出 Positive / Negative / Neutral 三種標籤，並給一句證據化理由。

步驟 3：聚合
根據各題結果，輸出一個整體結論：retain / exclude / unclear。
若任一核心條件明確為 Negative，傾向 exclude；若核心條件仍為 Neutral，傾向 unclear 而不是硬判 exclude。

這個模板的價值不在於逐字照抄，而在於它代表了一種決策分解方式。真正移植到 NLP / Speech 時，最重要的是把『criteria 的原子單位』定義清楚，而不是單純把 paper title 改掉。

3.3 家族 C：可校準的高召回 prompt（對應 Sanghera 2025）

公開程度 / fidelity	B 級。論文清楚描述 prompt 族群與『inclusion bias』調節，但未在論文全文中釋出所有 exact strings。
適用情境	適合你已經接受『這是一個 triage 工具，不是最後裁判』的場景。核心思想是不要把 prompt 當固定文字，而把它當 operating point：可以用 mild / moderate / heavy / extreme inclusion bias 去換取不同 recall。
常見失敗模式	這類 prompt 往往會把 recall 拉得很好，但 precision 會下降；若 downstream 沒有 adjudication 或 full-text routing，工作量可能爆炸。對 NLP / Speech 邊界極細的 topic，它也容易因『保守保留』而讓 maybe/inclusion 過多。

中文模板（可直接改寫）

你正在為一個 systematic review 做第一輪 title/abstract screening。

Review title：[review title]

Inclusion criteria：[criteria]

Study title：[title]

Study abstract：[abstract]

審核原則（heavy inclusion bias 版本）：

- (1) 只要題名或摘要出現任何與納入條件一致的直接訊號，就先保留。
- (2) 如果資訊不完整，但看不出明確排除理由，也先保留。
- (3) 只有在摘要直接顯示不符合關鍵條件時才排除。

輸出：Include 或 Exclude。

這個模板的價值不在於逐字照抄，而在於它代表了一種決策分解方式。真正移植到 NLP / Speech 時，最重要的是把『criteria 的原子單位』定義清楚，而不是單純把 paper title 改掉。

3.4 家族 D：先抽結構化 evidence，再做決策（對應 ReviewCopilot）

公開程度 / fidelity	A 級。ReviewCopilot repo 公開了 title/abstract 與 full-text prompt 程式碼。
適用情境	這是最推薦給你目前研究情境的模板家族。它把 decision 拆成兩段：先抽出結構化欄位，再比對 target criteria。這會讓每個決策更可追溯，也更容易在 OrionVault 裡保存 evidence object。
常見失敗模式	前半段的 extraction 若做錯，後半段 decision 會被連鎖污染；因此需要 schema 設計得足夠貼近領域，不可直接照搬 PICO。

中文模板（可直接改寫）

你的任務是判斷一篇文章是否應納入 systematic review；但你必須先抽出結構化 evidence，再做決策。

Target criteria schema：

Task = [task]

Input modality = [text/audio/...]

Output modality = [text/audio/...]

Model family = [transformer / diffusion / RLHF / ...]

Paper type = [primary empirical / benchmark / survey / position paper]

Evidence type = [method description / experiment / dataset / evaluation]

Study :

Title: [title]

Abstract or Full text: [text]

步驟 1：抽取欄位

回傳 JSON：task, input_modality, output_modality, model_family, paper_type, evidence_type, empirical_support, decision, rationale。

若某欄無法從文中抽出，填 ""。

步驟 2：做決策

只有在至少關鍵欄位被明確支持時才 include。

若資訊不清楚或關鍵欄位缺失，回傳 maybe / unclear，而不是自行腦補。

這個模板的價值不在於逐字照抄，而在於它代表了一種決策分解方式。真正移植到 NLP / Speech 時，最重要的是把『criteria 的原子單位』定義清楚，而不是單純把 paper title 改掉。

3.5 家族 E：多 reviewer / 多 agent + senior adjudication（對應 NLP_PRISMA_Reviews current workflow）

公開程度 / fidelity	A 級（對 repo 的 system prompt 規則來說）。你 repo 的 current runtime prompt 雖不是完整長模板，但核心 adjudication 規則公開。
適用情境	適合 criteria 邊界複雜、又需要完整 audit trail 的任務。關鍵不是讓 agent 彼此自由聊天，而是讓多個 reviewer 先給出分數、criteria evidence 與 uncertain points，再由 senior 依嚴格規則裁決。
常見失敗模式	如果全文在前處理時被截斷、junior extraction 不完整，或 senior 的 strict mode 沒有與 criteria schema 對齊，整個流程仍可能失真；但相比單體 classifier，這已經是更可稽核的方向。

中文模板（可直接改寫）

你是 Stage 1 senior adjudicator。你只能使用 title、abstract 與兩位 junior reviewer 的輸出；不可假設全文會補足缺失。

裁決規則：

- (1) 只接受輸入文字中可追溯的 evidence。
- (2) topic relevance、方法相似、領域相鄰，不等於符合納入條件。
- (3) 只有在至少一個核心正向訊號明確存在，而且剛好只缺一個關鍵條件時，才可給 maybe。
- (4) 若只是 topic-adjacent、metadata-like，或只提到關鍵字但沒有 eligibility evidence，偏向 exclude。
- (5) 理由中必須明說：已知正向 evidence 是什麼、缺的是什麼、為何缺失仍不足以保留或足以保留。

輸出：1-5 分，並映射到 exclude / maybe / include；同時列出 satisfied points、triggered exclusion points、uncertain points 與 evidence highlights。

這個模板的價值不在於逐字照抄，而在於它代表了一種決策分解方式。真正移植到 NLP / Speech 時，最重要的是把『criteria 的原子單位』定義清楚，而不是單純把 paper title 改掉。

4. LLM / agent 路線逐篇精讀

這一章按方法演化順序來讀：先看最簡單的單體 yes/no prompt，再看 criteria decomposition、high-recall calibration、extract-then-decide、整體 agentic orchestration，以及 multi-LLM collaboration。每篇都明確說出它的 experimental criteria 是什麼、它其實解的是什麼子問題，以及對 NLP / Speech 可轉移到哪裡。

4.1 Wang 2024：最簡單的單體 yes/no prompt

研究問題與任務	這篇工作問的是：在 title/abstract screening 階段，LLM 能否作為一個可校準的篩選器。作者不是要打造完整 agentic workflow，而是測試最簡 prompt 在不同模型與不同 operating point 下的表現。
研究領域	領域是生醫 systematic review screening。這一點很重要，因為這類資料的 criteria 通常比 NLP / Speech 規則化得多，很多 review 題目可被壓成一句簡潔敘述。
實驗 criteria	作者把 review topic 壓縮成一段短文字，再與 study 題名/摘要直接配對。也就是說，criteria 並沒有被拆成 task、study type、evidence 或 paper type 等子條件。
對應 prompt 家族	家族 A：單體 yes / no 判斷型 prompt。這是最短、最便宜、也最容易成為 baseline 的形式。
關鍵做法	重點不在 prompt engineering 的華麗程度，而在 calibration。作者比較多個 LLM，並把 decision threshold 調到預先指定的 recall 水準，再看可節省

	多少工作量。
重要數據	公開摘要顯示作者在五個 test collections 上評估八個 LLM，並強調 calibration 與 ensembles 可在指定 recall 門檻下節省 screening 時間。文中主報 F3 與 WSS，而不是只報 F1。
F1 重算	不建議強行重算單一 F1。因為這篇的重點是不同 recall operating point 下的工作量節省；若不知道最終採用哪個 threshold，單一 F1 反而會遮蔽方法本身。
對 NLP / Speech 的啟示	它最適合當 extremely cheap baseline，或當 ensemble 中的一票。但對你目前的 task 來說，它絕不應該是 final decision maker；因為像『是否 primary empirical study』、『是否真的做 process extraction 而不是 process prediction』這些條件，不能靠一個 yes/no prompt 穩定判對。

4.2 Akinseloyin 2024：把 criteria 拆成 QA

研究問題與任務	作者把 abstract screening 重新表述成 question-answering 任務：先把 selection criteria 轉成一小組問題，再逐題問模型。這和直接問『要不要納入』是不同哲學。
研究領域	資料來自 CLEF eHealth TAR 2019，涵蓋 intervention reviews 與 diagnostic test accuracy reviews。這表示 criteria 在醫學上已相當成熟，但 intervention 與 DTA 的 criteria 結構其實不同。
實驗 criteria	Selection criteria 會先被轉成最多 5 個問題。每個問題都要求模型用 Positive / Negative / Neutral 回答，再以 soft aggregation 或 reranking 轉成排序分數。作者也指出 GPT-3.5 在複雜 OR clauses 上表現不穩。
對應 prompt 家族	家族 B：逐條 criteria 問答型 prompt。
關鍵做法	這篇不是單純做 binary include/exclude，而是 prioritization。系統的目標是把更可能 relevant 的紀錄排到前面，因此主要指標是 MAP 與 WSS@95。
重要數據	在公開表格中，GPT_QA_Soft 與

	GPT_QA_Soft__GPT_Both_ReRank 等設定，在某些子集上能明顯提升 MAP 與 WSS@95；作者將其與傳統餘弦相似度基線比較，證明 criterion-aware QA 比單純文本相似度更能接近人工判準。
F1 重算	不建議。MAP / WSS@95 是這篇最合適的指標，因為系統先做排序，不是直接決定 final exclusion。若把 ranking 研究硬轉成 F1，反而會誤導 workflow 設計。
對 NLP / Speech 的啟示	這是最值得你吸收的 paper 之一。你完全可以把醫學裡的 question list，改寫成『是否處理自然語言文本』『是否目標是 process extraction』『是否為 primary research』『是否有 empirical validation』這種逐條問題。這樣的 criterion decomposition 比 monolithic prompt 更能處理命名混亂與邊界模糊。

4.3 Sanghera 2025：用 prompt 當 decision threshold

研究問題與任務	這篇關注的不是 agent collaboration，而是：若只做 title/abstract screening，怎樣的 prompt 設計與 ensemble 組合可以把 sensitivity 拉到很高，同時維持可接受的 precision。
研究領域	作者使用 23 個 Cochrane reviews，development set 800 citations，後續又在 119,695 citations 的複製資料集上測試。Cochrane review 的 criteria 通常寫得很正式，這讓 prompt 比較容易穩定。
實驗 criteria	每個 prompt 都會提供 review title 與 inclusion criteria；差異在於對納入傾向的 wording 強度，例如 none、mild、moderate、heavy、extreme。也就是說，criteria 本身不變，decision threshold 被嵌入 prompt wording 中。
對應 prompt 家族	家族 C：可校準的高召回 prompt。
關鍵做法	作者比較單一 prompt、平行 ensemble、串聯 ensemble，以及不同 LLM 之間的組合。invalid output 甚至被保守地當作 include，以避免 sensitivity 受損。

重要數據	development set 上，多種 LLM-human 與 LLM-LLM ensemble 可以做到 perfect sensitivity，但 precision 會顯著波動。這個結果非常說明問題：若你只要求『不要漏』，很多 prompt 都能做到；難的是如何在不漏的前提下，讓 downstream 工作量不要失控。
F1 重算	只能對少數公開了 precision 與 recall 的子設定補算，不適合對整篇做單一總 F1。理由是不同 prompt family 實際對應不同 operating point，而不是同一個 classifier。
對 NLP / Speech 的啟示	這篇最值得學的，不是哪個模型名最好，而是『prompt 也是 threshold』這個觀念。你未來可以對同一份 criteria 做 conservative / balanced / liberal 三個 prompt 版本，再把它們放進投票或 routing，而不是硬逼單一 prompt 同時做到高 recall 與高 precision。

4.4 Cao 2025 / srma : generic prompt templates

研究問題與任務	這篇試圖發展 generic prompt templates，讓研究者在新的 systematic review 上不必從零開始寫 screening prompt。與純研究型論文不同，它更像把 prompt template 做成產品級資產。
研究領域	BenchSR 來自己發表的生醫 systematic reviews，因此資料分布仍相當醫學化。這意味著模板設計對 PICO / study type 的依賴較強。
實驗 criteria	作者設計了 Abstract ScreenPrompt 與 ISO-ScreenPrompt。前者主要處理題名/摘要，後者處理全文。根據 paper 與 repo 說明，這些模板經過反覆 prompt revision、few-shot 與 self-consistency 迭代，而不是單次零樣本提問。
對應 prompt 家族	介於家族 C 與家族 D 之間：它既是 generic template，也帶有明確的 criteria 展開與高召回設計。
關鍵做法	作者不是只比較幾個模型，而是先把 prompt 本身當研究對象。這和很多只報模型名稱的 work 不同。srma repo 可看出它是一套完整 pipeline，包含

	message construction、batch execution、evaluation 與 model helpers。
重要數據	repo README 公開了 weighted sensitivity / specificity：abstract screening 為 97.7% / 85.2%，full-text screening 為 96.5% / 91.2%。這代表 generic prompt 若設計得當，確實可以逼近高品質人工表現。
F1 重算	不能只用 weighted sensitivity / specificity 直接算出『整體 weighted F1』，因為各 review prevalence 未公開。若硬算，只會得到不可信的平均。
repo 可重現性	srma repo 是公開的，但目前看到的主要是執行框架與呼叫邏輯；exact prompt strings 並沒有像 ReviewCopilot 那樣完整攤在 repo 裡。因此本報告把它標成『部分可重現』。
對 NLP / Speech 的啟示	這篇最大的價值是提醒你：prompt template 可以是可復用的基建。但你的 generic schema 不能再叫 PICO，而應該是 Task / Modality / Model Family / Paper Type / Empirical Evidence / Dataset Language。

4.5 ReviewCopilot 2025：先抽結構化 evidence，再做決策

研究問題與任務	ReviewCopilot 要做的不是理論 benchmark，而是給研究者一個可本地執行、可看理由、可批量跑的 AI screener。
研究領域	案例大多是生醫 systematic reviews，criteria 多以 PICOS 組織。這讓 extraction slot 很清楚，適合用 JSON 決策。
實驗 criteria	title/abstract prompt 要先抽出 Population、Intervention、Comparison、Outcome、Study type，再與 targeted PICOS 比對。全文 prompt 也是同一思想，只是輸入換成 PDF 文字。它還規定：若 2 個 PICOS 無法抽出，就傾向 exclude；若 unclear，則 include。
對應 prompt 家族	家族 D：先抽結構化 evidence，再做決策。
關鍵做法	repo 直接把 prompt 寫在程式裡，這對你很有價值，

	因為你可以實際看見一個能跑起來的產品級 prompt 長什麼樣，而不只是論文方法段。
重要數據	README 公布 validation performance： Sensitivity 0.976、Specificity 0.474、Precision 0.440、Recall 0.976、F1 0.606，資料來自 4 個已發表 systematic reviews、超過 6000 篇文章。這是一個非常典型的『高 sensitivity、低 specificity』產品型 screener。
F1 重算	已由 repo 直接提供，無需重算。
repo 可重現性	公開程度高。你可以直接看到 title/abstract 與 full-text 的 prompt 與 JSON schema；這使它成為非常好的 reverse engineering 對象。
對 NLP / Speech 的啟示	這是最容易直接轉成你工作流的 paper。你只需要把 PICOS 替換成更適合 NLP / Speech 的 schema，並把『若 unclear 就 include』保留下來，便能得到一個比單體 yes/no 更可稽核的 pipeline。

4.6 A4SLR 2025：agentic framework 不只 screening

研究問題與任務	A4SLR 關注的已不是單點 screening，而是整條 systematic literature review pipeline 的 agentic orchestration。這和只討論一個 classifier 差很多。
研究領域	用例來自 HEOR / HTA，包括非小細胞肺癌與 perinatal mood and anxiety disorders。這些場景的 full-text extraction、表格資料抽取與 risk of bias 任務都很重。
實驗 criteria	A4SLR 把 I/E criteria deployment 做成獨立模組，並讓 screening、text/table preprocessing、data extraction、risk of bias analysis 與 reporting 都由專門 agents 共同完成。
對應 prompt 家族	不只屬於單一 prompt 家族，而是『agentic framework』。對 screening 而言，它更接近家族 D + E 的組合；對整體流程而言，則是多模組 orchestration。
關鍵做法	8 個模組分工：search、criteria deployment、abstract/full-text screening、text/table

	preprocessing、data extraction、assessment、risk of bias、report。每一段都保留 human oversight。
重要數據	文章報告 screening F1 為 0.917-0.977，risk of bias Cohen's k 為 0.8442-0.9064，data extraction F-score 為 0.96-0.998。這些數字很強，但要注意它是一個 proof-of-concept framework，在特定用例上驗證。
F1 重算	已直接報告區間，無需重算。
對 NLP / Speech 的啟示	這篇的真正價值是告訴你：agentic AI 的收益不一定來自 screening classifier 本身，而可能來自整條 evidence pipeline 的模組化。若你未來想把 AUTOSR-SDSE 做成更完整系統，A4SLR 更像架構參考，而不是單一 screening 方法。

4.7 Akinseloyin 2026：multi-agent collaboration

研究問題與任務	這篇直接研究 multi-LLM collaboration 能否改善 abstract screening。它不是泛泛談『讓 agent 討論』，而是系統性比較不同聚合策略。
研究領域	仍用 TAR2019 benchmark，但規模明確寫出：20 個 intervention reviews 共 39,792 篇，8 個 DTA reviews 共 26,830 篇。任務是 title + abstract concatenated screening。
實驗 criteria	它承接 2024 JAMIA 的 QA decomposition，再在其上加入多模型 soft-vote、majority vote、debate、MAD、adjudication 等策略。也就是說，多 agent 不是替代 criteria decomposition，而是建立在 decomposition 之上。
對應 prompt 家族	家族 B 與家族 E 的結合：先逐條 QA，再做多 agent aggregation。
關鍵做法	核心變因不是模型大小本身，而是如何聚合多個回答。作者還分析了什麼樣的合作模式最能互補 individual LLM 的錯誤。
重要數據	公開摘要給出的代表性結果是：majority voting 在 intervention 與 DTA subsets 上分別達到 MAP

	0.462 / 0.341，WSS@95 為 0.606 / 0.680。對 abstract prioritization 來說，這是很具有說服力的提升。
F1 重算	不建議，原因與 2024 JAMIA 類似：這篇的主任務仍是 ranking / prioritization，而不是單一 binary classifier。
對 NLP / Speech 的啟示	若你真的要上 multi-agent，這篇提供了一個更健康的路徑：不要先讓 agent 自由對話，而是先讓每個 agent 回答對齊的 criterion questions，再做規則化 aggregation 或 senior adjudication。這樣比較容易存進 vault，也比較好 debug。

4.8 2026 新趨勢補充：fine-tuning 與 validation

研究問題與任務	2026 年一個值得注意的新方向是：與其一直微調 prompt，不如直接對 screening 資料 fine-tune 一個小型 LLM。
研究領域	Yamoah et al. 使用 8,500+ 筆由人工標註的教育科技 systematic review screening 資料，屬於非典型生醫場景，因此對跨領域遷移特別有參考價值。
實驗 criteria	criteria 仍然由人工標註規則定義，但模型學到的是整體 decision boundary，而不是靠單一 prompt 臨場推理。
對應 prompt 家族	嚴格說已經超出 prompt family，而是『task-specific fine-tuning』。
重要數據	作者報告 weighted F1 相較 base model 提升 80.79%；在 8,277 studies 上，true positive rate 91.18%，true negative rate 86.38%，且多次推論結果一致。
對 NLP / Speech 的啟示	若你未來在某個 topic 上累積到足夠人工 gold，fine-tuning 可能比 endlessly prompt engineering 更穩。但在資料量不足前，criterion decomposition + adjudication 仍然更務實。

5. 傳統但更有創新性的 screening workflow 逐篇精讀

這條線刻意不只討論單人或雙人審核，而是看更重要的設計問題：哪些排除需要複核、怎樣把 crowd 或 ML 放進流程、哪些做法能在不破壞 recall 的前提下真的減少工作量。這一章的核心訊息是：流程創新往往比 reviewer 人數本身更重要。

5.1 Gartlehner 2020：單人審核風險的基準線

研究問題與任務	這篇是理解 SR screening 風險最重要的基準線之一。它直接比較 single-reviewer 與 dual-reviewer abstract screening 的表現差異。
研究領域	研究基於兩個已發表的 systematic reviews，讓 280 位參與者對 2,000 篇 abstracts 做篩選，總共產生 24,942 個 screening decisions。
實驗 criteria	criteria 由兩個 reference standard reviews 預先定義。研究重點不是 automation，而是 quantifying 人類單人審核本身的錯誤率。
關鍵做法	利用 crowd-based randomized controlled design，比較一位 reviewer 單獨決策與兩位 reviewer 配對時的 sensitivity / specificity。
重要數據	single-reviewer abstract screening 的 sensitivity 為 86.6%，specificity 為 79.2%；dual-reviewer sensitivity 為 97.5%，specificity 為 68.7%。換句話說，單 reviewer 平均漏掉了約 13% relevant studies，而雙 reviewer 約漏 3%。
F1 重算	僅憑目前可取得的摘要與 snippets，缺少 prevalence / contingency table，因此不宜偽精確重算整體 F1。
對你的問題的意義	這篇告訴我們：任何『單 reviewer + 強模型』的自動化，如果沒有額外 verification 機制，就很可能重演單 reviewer 的 false exclusion 風險。

5.2 Nama 2021：依排除理由決定是否複核

研究問題與任務	Nama 2021 要解決的是：能不能在保住 sensitivity 的前提下，讓部分排除決策不必再做第二人複核。
研究領域	作者分析 24 個 systematic reviews，共 930 篇 eligible 與 27,390 篇 ineligible citations，多數在兒

	科，但涵蓋多種專科。
實驗 criteria	作者不只看最終 include/exclude，而是看『是基於哪種 exclusion category 被排除』以及『被標記了幾個 exclusion criteria』。
關鍵做法	他們發展並驗證多個 single-reviewer algorithms，決定哪些排除可以直接接受、哪些仍需 second-review verification。這本質上是一個 verification routing 問題。
重要數據	若單 reviewer 直接排除任何 citation，平均 sensitivity loss 為 8.6%。若只對標到兩個以上 exclusion criteria 的紀錄直接排除，平均 sensitivity loss 降到 1.2%。另外，有五種 exclusion categories 在此資料上表現出 perfect sensitivity：conference abstract、ineligible age group、case report/series、not human research、review article。
F1 重算	不可可靠重建，因為公開可得資料以 sensitivity loss 與 work-saved 為主，沒有足夠 confusion details。
對 NLP / Speech 的意義	這篇極值得借鏡。你可以把『無 full text』『明顯 survey/review』『明顯非 primary research』『輸出 modality 明確不符』『topic 完全錯位』這些低風險排除類別先做 metadata / rule gate；但把 paper type 模糊、evidence 不足、task boundary 微妙的紀錄送去複核。

5.3 Noel-Storr 2021：crowd + ML hybrid

研究問題與任務	這篇評估的是 Cochrane modified Screen4Me：先用 machine learning classifier 淘汰明顯非 RCT，再用受訓 crowd 處理剩餘紀錄。
研究領域	場景是 Cochrane rapid reviews 的 study identification，特別是 COVID-19 相關 RCT 尋找。這是一個 living, high-volume, time-sensitive 場景。
實驗 criteria	最核心的 eligibility 是『是否為可能相關的 RCT』。換言之，criteria 沒有像 full SLR 那樣多維，但

	recall 要求極高。
關鍵做法	這是一個標準 hybrid workflow：ML 先做 coarse filtering，crowd agreement algorithm 再做高 recall 判定。重點在 workflow 配置，而非單一模型。
重要數據	公開摘要顯示 crowd agreement algorithm 達到 100% sensitivity 與 80.71% specificity；同時，前面的 RCT machine learning classifier 沒有拒掉任何最終納入研究。
F1 重算	由於 accessible sources 未提供該子研究的 prevalence / contingency details，不能可靠重建 F1。
對 NLP / Speech 的意義	這種兩段式設計非常值得用在你的 pipeline：先用 cheap gate 去掉明顯不可能 relevant 的紀錄，再把剩餘紀錄交給更昂貴但更可追溯的 multi-agent 或人工複核。

5.4 Pham 2021：semi-automated workflow

研究問題與任務	Pham 2021 關注的是 accessible semi-automated workflow，而不是單一高性能模型。它想回答：text mining 能否與人工流程組合成一條實用路線。
研究領域	作者同時在一個 type 1 diabetes systematic review 與一個 knowledge synthesis methods 的 scoping review 上驗證 workflow。也就是說，它不只測單一醫學子領域。
實驗 criteria	criteria 來自兩個實際 review 的納排規則；工具先做 text-mining / prioritization，再與人工程序結合。
關鍵做法	這不是完全自動化，而是 semi-automated workflow。作者明確把 workload reduction、person-hours 與漏掉多少 full-text 候選一起報出。
重要數據	在 type 1 diabetes SR 上，workflow 的 sensitivity 88%、precision 71%、F1 79%、specificity 99.3%、workload reduction 63%，等於節省 91 人工小時。於 knowledge synthesis scoping review 上，sensitivity 89%、precision 72%、F1 79%、

	specificity 99.3%、workload reduction 55%，等於節省 95 人工小時。
F1 重算	已直接報告，無需重算。
對 NLP / Speech 的意義	這篇提醒你：不要只追求 classifier 分數，也要報『省了多少人工時間』『漏掉幾篇後續全文候選』『最終 completed review 是否受影響』。這些是 workflow paper 應該看的指標。

5.5 Shemilt 2022 : living evidence 的 recall-calibrated classifier

研究問題與任務	Shemilt 2022 研究的是一個 living evidence register 維護場景：如何用 ML classifier 減少持續更新時的人工 study identification 工作量。
研究領域	Cochrane COVID-19 Study Register，是高流量、持續更新、時間敏感的 evidence infrastructure。
實驗 criteria	核心任務是辨識 COVID-19 研究 study reports 是否應被收進 register。這和一般 topic-specific SR screening 不完全相同，但對 living review 特別有參考價值。
關鍵做法	作者用 59,513 筆 records 訓練、16,123 筆校準，目標 recall > 0.99，再在獨立 evaluation set 上測試。這是標準的 recall-calibrated classifier pipeline。
重要數據	最終 classifier 抓回了 2,285 / 2,310 篇 eligible reports，recall 約 98.9%，precision 0.638，net screening workload reduction 24.1%。這代表 living review 場景可以接受 moderate precision，只要 recall 足夠高且節省工作。
F1 重算	可近似重算：若 precision = 0.638、recall = 0.989，則 F1 約為 0.776，F2 約為 0.891，F3 約為 0.937。對 living evidence 任務來說，F2 / F3 比 F1 更有意義。
對 NLP / Speech 的意義	若你未來做的是持續更新某個 survey topic，而不是一次性的 review，這篇的 workflow 很重要。對 living pipeline，重要的不是一次做到完美 precision，而是建立一個可長期運轉的高 recall 前哨站。

5.6 ASReview LAB v2 2025：shared model + crowd of experts

研究問題與任務	ASReview LAB v2 不是一篇單一方法 paper，而是一個成熟平台的 workflow 升級：把 active learning、多人協作與多模型切換整合到同一個 screening 環境。
研究領域	它是通用文字篩選平台，不只服務醫學。這對 NLP / Speech 特別重要，因為你不必被 PICO 框架綁住。
實驗 criteria	criteria 本身由使用者或 expert crowd 標註 relevant / not relevant。平台的重點是如何讓 shared AI model 與多人標註互動，而不是事先假設 criteria 的固定結構。
關鍵做法	v2 支援 collaborative screening with multiple experts (a crowd of oracles)，並允許在同一專案中切換 fast general-purpose、domain-specific、semantic、multilingual models。
重要數據	Patterns 論文摘要指出，基於 SYNERGY benchmark 的模型改進與超參數調整，讓 version 2 相對 version 1 的 loss 降低 24.1%。ASReview 生態系的模擬研究則經常報告可節省大量工作量。
F1 重算	不適合。ASReview 的核心是 active learning / loss / work saved，而不是單一靜態 confusion matrix。
對 NLP / Speech 的意義	它提供了另一條很值得借鑑的路：不是每個 topic 都要重新發明 agentic review 流程。你可以把 ASReview 那種『shared model + crowd of experts + stopping rule』思想，與你自己的 criteria decomposition 結合。

6. 把醫學 SR 的 criteria 轉譯到 NLP / Speech

醫學 systematic review 的 criteria 為什麼比較容易被 prompt 化？因為很多 review 天然有穩定的 schema。以 intervention review 為例，Population、Intervention、Comparison、Outcome、Study design 這五個槽位已足夠覆蓋大部分 eligibility。即使有例外條款，reviewer 仍可用一種相對固定的 mental model 去審核 abstract。

但 NLP / Speech 不是這樣。對你目前的研究題目而言，真正的 eligibility 常常跨越至少六個層面：第一是 task scope，例如 process extraction、syntax analysis、preference-based learning；第二是 modality，例如輸入是自然語言文字還是音訊，輸出是否仍是 audio；第三是 model family，例如是否限於 Transformer language models；第四是 paper type，例如 primary empirical article、benchmark、survey、position paper；第五是 evidence type，例如是否真的有 method + experiment，而不是只做概念討論；第六是 data / language 限制，例如 full text、English、dataset language 等。

因此，若你把醫學 paper 裡的 PICOS prompt 直接搬過來，通常會出現兩種錯誤。第一種是槽位錯置：例如把『Population』硬對應成『研究對象』，但 NLP paper 真正關鍵的不是 population，而是 task 與 evidence。第二種是 evidence 位置錯置：醫學 RCT 的關鍵資訊常常會在 abstract 中較完整，而 NLP / Speech 的決定性訊號則常藏在方法節、附錄、benchmark appendix、或 dataset description。

對於 NLP / Speech，我建議用以下 schema 取代 PICOS。必備欄位至少包括：Task、Input Modality、Output Modality、Model Family、Paper Type、Empirical Evidence、Dataset / Language、Full-text Availability。若你要做更高精度的 screening，還可再加上 Learning Signal、Evaluation Setup、Main Artifact、以及是否 secondary research。

醫學 SR 常見槽位	NLP / Speech 對應槽位	在 screening 時實際要找的訊號
Population	研究任務或問題定義	例如 syntax analysis、process extraction、audio generation、preference learning；不是只看領域名詞，而是看 paper 真正解決的任務。
Intervention	模型家族 / 系統設計 / 訓練機制	例如 transformer、diffusion、RAG、RLHF、ranking-based preference optimization；要能從方法節或實驗設計中定位。
Comparison	baseline / comparator / ablation 設計	在 NLP / Speech 常不是硬性 inclusion，但對後續 evidence extraction 很重要。
Outcome	證據型態與評估方式	是否真的做 empirical validation、是否只是概念論述、是否只有 qualitative demo、是否有人類偏好或任務成效指標。
Study design	paper type / research type	primary empirical research、benchmark、dataset paper、survey/review、position paper；這一欄對排除 non-primary research 特別重要。

Setting / sample	資料型態 / 模態 / 語言	是 text 還是 speech / audio / multimodal；是否只處理標籤序列而非自然語言；是否需要英文全文。
------------------	----------------	---

下面四個例子來自 NLP_PRISMA_Reviews 的 stage-2 criteria JSON。它們非常適合展示：在 NLP / Speech review 中，真正讓 screening 變難的不是模型能力本身，而是 criteria 的邊界細、子條件多，而且決定性訊號常常藏在方法節或附錄。

6.1 2409.13738 : NLP for process extraction

2409.13738 : NLP for process extraction 的 criteria 摘要

這篇 review 的核心是『NLP for process extraction from natural-language text』。納入條件要求 full research article、full text available、English、primary original research、主題明確是以 NLP 從自然語言文本中做 process extraction，且要有具體方法與實證驗證。排除條件則明確把 process redesign、matching、prediction、sentiment analysis、只針對個別 labels、從 process 生成自然語言、以及沒有具體 NLP 方法或缺乏驗證的工作排除。這類 criteria 對 abstract 的要求非常高，因為 paper 可能看起來『很像 business process mining』，但其實不是 process extraction。

6.2 2307.05527 : generative audio models

2307.05527 : generative audio models 的 criteria 摘要

這篇關注 generative audio models 的倫理意涵。條件要求 paper 必須是 full research paper，主題主焦 generative audio model 或其應用，而且最終輸出必須完全是 audio。排除則明確指向 speech-to-text / ASR 文字輸出、video generation、多模態輸出不是純 audio、以及根本不是 generative audio。這是典型的 modality-sensitive criteria；只要 prompt 沒有把 output modality 做成顯式欄位，就很容易判錯。

6.3 2511.13936 : audio-domain preference learning

2511.13936 : audio-domain preference learning 的 criteria 摘要

這篇要求的是『audio domain 中的 preference-based learning』。重點不只是有 preference 這個字，而是 preference 是否真的用於 learning。A/B comparisons、ranking、numeric ratings 轉排名、human 或 synthetic preferences 都可以；但若 preferences 只被拿來 evaluation，而沒有進入 learning loop，就應排除。這種 criteria 特別容易被 monolithic prompt 誤判，因為 abstract 很常會提到 preference evaluation，卻不代表 preference-based learning。

6.4 2601.19926 : transformer LM + syntax

2601.19926 : transformer LM + syntax 的 criteria 摘要

這篇 review 針對 Transformer-based language models 中的 syntactic knowledge interpretability research。納入需要同時滿足兩件事：研究對象確實是 Transformer-based language models，而且論文有 empirical analysis of syntax。排除則會打掉非 Transformer 架構、以 machine translation 為主的 encoder-decoder 研究、沒有真正分析 syntax 的 paper，以及沒有 empirical component 的 survey / position paper。這類 criteria 看似簡單，但 abstract 裡很常出現『syntax』或『transformer』字樣，真正是否符合還要看方法與實驗。

7. NLP_PRISMA_Reviews 深入案例分析：為什麼 GPT-5.4 單 reviewer 還是會差

這一章不是要證明單 reviewer 一定不好，而是要把『為什麼強模型在你的場景下仍會失手』拆開。若只看模型名稱，很容易得到錯誤結論；真正影響結果的，是 workflow 設計、criteria 表示法、evidence 可見性、以及 evaluation target。

你在對話中指出的一個核心現象是：`NLP\_PRISMA\_Reviews` 裡用 GPT-5.4 做單 reviewer 審核，表現仍不理想。若只從表面看，這會讓人以為『LLM 再強也不行』。但讀完 repo 之後，我的結論剛好更精確：問題主要不在模型名稱，而在這個 baseline 的 workflow 假設，與你目前任務的 criteria 形狀彼此不匹配。

首先，這個單 reviewer run 本身就不是 production workflow，而是 repo 明確標註的 experiment-only baseline。template 直接寫明：不修改 current production runtime prompts，不沿用 preserved workflow，只使用 Stage 2 criteria JSON、title、abstract、full text 做判斷。這代表它是一個刻意簡化的比較基線，而不是 repo 作者認為最終應採用的正式流程。

第二，這個 baseline 把複雜 eligibility 壓縮成單一 `stage\_score`（1 到 5）。這在看似簡潔的同時，其實犧牲了 criterion decomposition。像 `2409.13738` 這類 topic，真正要判斷的是：是不是 full research article、是不是 primary research、是不是 NLP for process extraction、是不是從 natural-language text 出發、是不是有 concrete method、是不是有 empirical validation。把這麼多條件壓成一個分數，模型更容易被 topic adjacency 帶走。

第三，repo current workflow 的 senior adjudicator 其實已經意識到這個風險，所以 prompt 規則明確寫道：不得把 topic relevance、conceptual similarity、method similarity 或 domain adjacency 當成 sufficient inclusion evidence；只有當至少一個核心正向 signal 明確存在，而且剛好只缺一個關鍵條件時，才允許 maybe。換句話說，current workflow 已經從 prompt 層面禁止『看起來有點像』這種模糊納入。

第四，single-reviewer baseline 的 reported F1 也有解讀陷阱。metrics JSON 明確寫 `positive\_mode = include\_or\_maybe`，也就是評估時計算 TP / FP / FN 時，把 maybe 視為

positive。這種計法在 screening 研究裡不算錯，但 operationally 它意味著：你看到的 F1，其實是『include 或至少值得人工再看』的 F1，而不是『全自動做出最終 include/exclude』的 F1。若 maybe 仍需要人工複核，該 F1 會比真實 automation yield 更樂觀。

第五，全文截斷是一個極其實際而且被忽視的原因。根據 repo 的 batch results，我重新統計後發現：84 筆紀錄裡有 47 筆 hit 到約 36,028 字元上限。最極端的幾篇長文，例如 `omg\_uuml`、`omg\_bpmn`、`omg\_dmn`，實際只保留了原始全文的大約 2.0%、3.9%、7.4%。若決定性 evidence 位在方法節、附錄或後段 benchmark 設定中，單 reviewer 其實是在殘缺證據上做 final call。

第六，從指標選擇來看，single-reviewer baseline 的 F1 之所以看起來不錯，是因為它比較保守地把正例壓到 22 個，只產生 4 個 FP；而 current workflow 為了保住 recall，把更多邊界案例留了下來，正例數變成 35 個，因此 precision 下降。結果是：single-reviewer baseline 的 F1 較高，但 current workflow 的 recall = 1.0，而且 F2 與 F3 更高。對 SR screening 而言，後者其實更符合任務目標。

總結來說，`NLP\_PRISMA\_Reviews` 的單 reviewer GPT-5.4 baseline 並不是在證明『GPT-5.4 不行』，而是在證明：對 criteria 邊界細、命名混亂、evidence 分散於全文後段的 NLP / Speech review 來說，workflow design 比模型名稱更重要。真正該追求的不是『單 reviewer 一步到位』，而是把 metadata gate、criterion decomposition、evidence extraction、uncertainty routing 與 adjudication 綁在一起。

Workflow	Precision	Recall	F1	F2	F3
單 reviewer baseline	0.818	0.857	0.837	0.849	0.853
current authority workflow	0.600	1.000	0.750	0.882	0.938

Workflow	TP	FP	FN	TN
單 reviewer baseline	18	4	3	59
current authority workflow	21	14	0	45

最嚴重截斷樣本	全文字數	實際送入字數	使用比例
omg_uuml	1,775,255	36,028	0.020
omg_bpmn	927,669	36,028	0.039

omg_dmn	484,522	36,028	0.074
gupta2024navigating	217,773	36,028	0.165
zhao2024_rag_applic	140,909	36,028	0.256

圖 3 為什麼單 reviewer + 強模型仍可能在 SR screening 中表現不穩

以 NLP_PRISMA_Reviews 中的 GPT-5.4 single-reviewer baseline 為例：問題不在模型名稱本身，而在 workflow design 與 evaluation target。




圖 3. 為什麼單 reviewer + 強模型仍可能在 NLP / Speech criteria 下失穩。

圖中把失敗來源拆成五層：criteria 壓縮、摘要資訊不足、全文截斷、maybe 評分口徑、以及 recall-priority 任務目標。對 SR screening 來說，真正應優化的通常不是 raw F1，而是低 false exclusion 風險。

8. 給 OrionVault / multi-agent survey generation pipeline 的建議流程

如果你的目標是把 screening 接到 Automatic Survey Generation pipeline，而不是只做 benchmark 演示，那麼 workflow 必須滿足四件事：高 recall、可稽核、能把不確定性路由到更昂貴但更可靠的步驟、以及能把中間證據保存到 Vault 讓不同 agent 共用。

圖 2 適用於 NLP / Speech systematic review 的建議 screening pipeline

核心原則：把 criteria 拆成可稽核物件；把 uncertain cases 保留下來；把最終排除集中在 evidence 充分且可回查的節點。



圖 2. 推薦給 NLP / Speech systematic review screening 的 pipeline。

這條流程刻意把最便宜的 metadata gate 放在最前面，把最昂貴的 full-text 與 senior adjudication 放在後面。如此可以讓 token 與人工時間集中在用在高風險樣本，而不是平均灑在所有 citation 上。

階段	應保存到 OrionVault 的內容	作用
Stage 0：metadata gate	題名、摘要、年份、語言、全文可得性、出版型態	先把 review、tutorial、poster、無全文、非英文等機械性排除條件處理掉，避免昂貴 agent 把 token 浪費在低價值樣本上。
Stage 1：criteria decomposition	由 protocol 產生 task / modality / model family / paper type / evidence type 的核對問題	把 criteria 變成可審核的最小單元，讓每個 agent 回答的不是『像不像主題』，而是『是否有可追溯證據滿足某條件』。
Stage 2：cheap high-recall triage	一到兩個便宜模型做 liberal include / maybe	只要有一個核心正向 signal 就先保留，目的是把 recall 拉高。
Stage 3：routed full-text review	只對高風險樣本抓全文或長上下文	對摘要不足、criteria 很細、或題名抽象的 paper 啟用全文審核，降低因摘要缺訊號而誤排除。
Stage 4：senior adjudication	以嚴格規則整合 junior outputs	Senior 只能看可追溯 evidence；不允許 topic adjacency 直接過關；把 maybe 變成真正的人工複核佇列。

Stage 5 : audit trail	在 OrionVault 保存 prompts、criteria 版本、每條 evidence span、最後判決	讓 pipeline 可以被回溯、可比較、可做 error analysis，也方便不同 agent 共享 system memory。
-----------------------	---	--

最小可行規格 (MVP)

若你現在就要做第一版，我建議至少先實作四件事：一，criteria decomposition；二，junior reviewer 與 senior adjudicator 分層；三，只有高風險樣本才進全文；四，所有判決都必須保存 evidence span、criteria version 與 prompt version。這四件事的回報通常比單純換更大模型還高。

9. 結論

把近兩年的研究串起來看，screening workflow 的主線不是從『人工』走向『完全自動化』，而是從『單次不可解釋判斷』走向『可分解、可校準、可路由、可稽核』。這也是為什麼 multi-agent 與 adjudication 會越來越重要：它們處理的不是模型知識量，而是不確定性管理。

對 NLP / Speech 而言，真正需要學的不是醫學 PICO 文字本身，而是背後的 protocol discipline：criteria 必須先被拆成可核對的槽位與問題，然後才能讓人或 agent 穩定審核。若 criteria 仍是含糊的大段自然語言，任何單 reviewer workflow 都容易把主題相似誤判成符合條件。

最後，NLP_PRISMA_Reviews 的例子說明了一件很實際的事：當任務本質是 high-recall screening 時，不能只看單一 F1。你真正要防的是 false exclusion，也就是把該納入的研究提早扔掉。從這個角度看，current workflow 雖然 precision 較低，但更符合 systematic review 的風險結構。

附錄 A. Prompt 原文片段與英文規格化模板

這個附錄分成兩種情況。第一種是 paper 沒公開完整 prompt，只能根據 methods section 做 method-faithful reconstruction；第二種是 GitHub repo 公開了接近原始 prompt 的程式碼，此時可提供更接近原文的 normalized English version。為了避免把 paper 或 repo 的長段文字整段複製，本附錄統一採『英文規格化模板』方式呈現。

A1. Wang 2024 型：normalized English template

English template

You are a first-pass systematic review screener.

Task: Based only on the review question and the provided study title/abstract, decide whether the study should be retained for the next stage.

Review topic / inclusion focus:

[review topic]

Study:

Title: [title]

Abstract: [abstract]

Respond with only one label: include or exclude.

Notes:

This normalized template reflects the paper's minimalist yes/no setup. The exact wording varied across experiments and calibration settings. The paper's key contribution is not prompt richness but operating-point calibration.

A2. Akinseloyin 2024/2026 型：normalized English template

English template

You are a systematic review screener.

Selection criteria:

[criteria]

Study:

Title: [title]

Abstract: [abstract]

Step 1. Convert the selection criteria into up to five non-overlapping eligibility questions.

Step 2. For each question, answer Positive / Negative / Neutral using only evidence traceable to the title/abstract.

Step 3. Produce a short justification for each answer.

Step 4. Aggregate the answers into a ranking or inclusion priority score.

Notes:

This is a reconstructed method-faithful template based on the papers' method descriptions rather than a

public verbatim prompt dump.

A3. Sanghera 2025 型 : normalized English template

English template

You are screening citations for a systematic review.

Review title: [review title]

Inclusion criteria: [criteria]

Study title: [title]

Study abstract: [abstract]

Screening principle (high-recall version):

- If the study clearly matches the criteria, include.
- If the evidence is incomplete but there is a plausible signal of relevance, include.
- Only exclude when the title/abstract provides clear evidence of ineligibility.

Output one label: include or exclude.

Notes:

The published study explored several prompt variants (none/mild/moderate/heavy/extreme), which effectively changed the decision threshold while keeping the criteria constant.

A4. ReviewCopilot 型 : public prompt family, normalized from code

English template

Determine whether the article should be included in a systematic review by first extracting structured PICOS-style evidence and then comparing it with the target criteria.

Target schema:

Population = [...]

Intervention = [...]

Comparison = [...]

Outcome = [...]

Study type = [...]

Study:

Title / Abstract or Full text = [...]

Instructions:

1. Extract the study's structured evidence.
2. Compare each extracted field against the target schema.
3. Return a JSON object containing the extracted fields, a final decision, and a short rationale.

4. If the evidence is unclear or uncertain, err on the side of inclusion.

Notes:

The public GitHub repository exposes close-to-exact prompt code for both title/abstract and full-text modes.

A5. NLP_PRISMA_Reviews current workflow 型：public senior-adjudicator logic, normalized

English template

You are the Stage 1 senior adjudicator.
You may use only the title, the abstract, and the junior reviewers' outputs.
Do not assume that unseen full text will rescue missing evidence.

- Decision rules:
- 1. Accept only evidence traceable to the provided text.
 - 2. Topic similarity, conceptual adjacency, or method resemblance is not sufficient for inclusion.
 - 3. Use MAYBE only when at least one core positive signal is explicitly present and exactly one key eligibility condition is still unresolved.
 - 4. Otherwise return INCLUDE or EXCLUDE with a short rationale and cited evidence spans.

Notes:
This template is normalized from the public runtime prompt. The public repo contains stricter operational rules than the experiment-only single-reviewer baseline.

附錄 B. 各 paper 的 criteria 與領域摘要

這個附錄把每篇 paper 的實驗場景縮成三個軸：研究領域、criteria 形式、以及對 NLP / Speech 的轉移價值。主文已逐篇詳解；這裡提供更適合回查的壓縮版。

Paper / workflow	研究領域（壓縮）	criteria 形式（壓縮）
Wang2024 ECIR	領域是生醫 systematic review screening。這一點很重要，因為這類資料的 criteria 通常比 NLP / Speech 規則化得多，很多 re...	作者把 review topic 壓縮成一段短文字，再與 study 題名/摘要直接配對。也就是說，criteria 並沒有被拆成 task、study type、evidence 或 paper t...
Akinseloyin2024 JAMIA	資料來自 CLEF eHealth TAR 2019，涵蓋 intervention reviews 與 diagnostic test accuracy reviews。...	Selection criteria 會先被轉成最多 5 個問題。每個問題都要求模型用 Positive / Negative / Neutral 回答，再以 soft aggregation 或 r...
Sanghera2025 JAMIA	作者使用 23 個 Cochrane reviews，	每個 prompt 都會提供 review title 與

	development set 800 citations，後續又在 119,695 citations 的複製資料集…	inclusion criteria；差異在於對納入傾向的 wording 強度，例如 none、mild、moderate、heavy、e…
Cao2025 AnnInternMed srma	BenchSR 來自己發表的生醫 systematic reviews，因此資料分布仍相當醫學化。這意味著模板設計對 PICO / study type 的依賴較強。	作者設計了 Abstract ScreenPrompt 與 ISO-ScreenPrompt。前者主要處理題名/摘要，後者處理全文。根據 paper 與 repo 說明，這些模板經過反覆 prompt…
ReviewCopilot2025	案例大多是生醫 systematic reviews，criteria 多以 PICOS 組織。這讓 extraction slot 很清楚，適合用 JSON 決策。	title/abstract prompt 要先抽出 Population、Intervention、Comparison、Outcome、Study type，再與 targeted PICOS 比…

Paper / workflow	研究領域（壓縮）	criteria 形式（壓縮）
A4SLR2025 ValueInHealth	用例來自 HEOR / HTA，包括非小細胞肺癌與 perinatal mood and anxiety disorders。這些場景的 full-text extract…	A4SLR 把 I/E criteria deployment 做成獨立模組，並讓 screening、text/table preprocessing、data extraction、risk of…
Akinseloyin2026 BMP	仍用 TAR2019 benchmark，但規模明確寫出：20 個 intervention reviews 共 39,792 篇，8 個 DTA reviews 共 26…	它承接 2024 JAMIA 的 QA decomposition，再在其上加入多模型 soft-vote、majority vote、debate、MAD、adjudication 等策略。也就是說…
FineTune2026	Yamoah et al. 使用 8,500+ 筆由人工標註的教育科技 systematic review screening 資料，屬於非典型生醫場景，因此對跨領域遷移特…	criteria 仍然由人工標註規則定義，但模型學到的是整體 decision boundary，而不是靠單一 prompt 臨場推理。
Gartlehner2020	研究基於兩個已發表的 systematic reviews，讓 280 位參與者對 2,000 篇 abstracts 做篩選，總共產生 24,942 個 screenin…	criteria 由兩個 reference standard reviews 預先定義。研究重點不是 automation，而是 quantifying 人類單人審核本身的錯誤率。
Nama2021	作者分析 24 個 systematic reviews，共 930 篇 eligible 與 27,390 篇 ineligible citations，多數在兒科，但涵…	作者不只看最終 include/exclude，而是看『是基於哪種 exclusion category 被排除』以及『被標記了幾個 exclusion criteria』。

Paper / workflow	研究領域（壓縮）	criteria 形式（壓縮）
NoelStorr2021	場景是 Cochrane rapid reviews 的 study identification，特別是 COVID-19 相關 RCT 尋找。這是一個 living, ...	最核心的 eligibility 是『是否為可能相關的 RCT』。換言之，criteria 沒有像 full SLR 那樣多維，但 recall 要求極高。
Pham2021	作者同時在一個 type 1 diabetes systematic review 與一個 knowledge synthesis methods 的 scoping re...	criteria 來自兩個實際 review 的納排規則；工具先做 text-mining / prioritization，再與人工程序結合。
Shemilt2022	Cochrane COVID-19 Study Register，是高流量、持續更新、時間敏感的 evidence infrastructure。	核心任務是辨識 COVID-19 研究 study reports 是否應被收進 register。這和一般 topic-specific SR screening 不完全相同，但對 living r...
ASReviewV2	它是通用文字篩選平台，不只服務醫學。這對 NLP / Speech 特別重要，因為你不必被 PICO 框架綁住。	criteria 本身由使用者或 expert crowd 標註 relevant / not relevant。平台的重點是如何讓 shared AI model 與多人標註互動，而不是事先假設 c...

附錄 C. F1 / F2 / F3 重算說明

本報告對『能可靠重算』與『不宜硬算』做了嚴格區分。只有在 paper 或 repo 至少提供 precision 與 recall，或提供足夠的 confusion-matrix 資訊時，才補算 F1 / F2 / F3。若研究的主任務是 ranking、prioritization、MAP、WSS@95，且沒有穩定二元決策門檻，則不強行轉成 F1。

F1 定義為 $2PR / (P + R)$ ；F2 定義為 $5PR / (4P + R)$ ；F3 定義為 $10PR / (9P + R)$ 。在 systematic review screening 場景下，F2 與 F3 往往比 F1 更貼近任務風險，因為漏掉該納入研究的代價通常大於多留一些待複核樣本。

NLP_PRISMA_Reviews 的單 reviewer baseline 在目前可見 run 上，Precision = 0.818，Recall = 0.857，所以 F1 = 0.837，F2 = 0.849，F3 = 0.853。current authority workflow 的同組數值則為 Precision = 0.600，Recall = 1.000，F1 = 0.750，F2 = 0.882，F3 = 0.938。這一對數字正好展示：若只看 F1，會低估高 recall workflow 的價值。

參考文獻

下列來源同時包含 paper、官方說明頁、與公開 repo。若某篇 paper 的完整 prompt 沒公開，本文會在主文或附錄中清楚標示為 method-faithful reconstruction，而不是逐字轉錄。

[R1] Page MJ, McKenzie JE, Bossuyt PM, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ (2021). [連結](#)

- [R2] Cochrane Handbook, Chapter 4: Searching for and selecting studies; Technical Supplement (2024 update). [連結](#)
- [R3] Wang X, et al. Large language models for systematic review screening: evaluation and calibration. arXiv:2401.06320 (2024). [連結](#)
- [R4] Akinseloyin O, Jiang X, Palade V. A question-answering framework for automated abstract screening using large language models. JAMIA 31(9):1939-1952 (2024). [連結](#)
- [R5] Sanghera R, et al. Sensitivity and specificity of using LLMs for title and abstract screening in systematic reviews and meta-analyses / Optimal large language models to screen citations for systematic reviews. JAMIA 32(5):893-905 (2025). [連結](#)
- [R6] Cao JZ, et al. Development of Prompt Templates for Large Language Model-Driven Screening in Systematic Reviews. Annals of Internal Medicine / srma repo (2025). [連結](#)
- [R7] ReviewCopilot open-source repository and released screening prompts (2025). [連結](#)
- [R8] Lee K, et al. A4SLR: An Agentic Artificial Intelligence-Assisted Systematic Literature Review Framework to Augment Evidence Synthesis for HEOR and HTA. Value in Health 28(11):1655-1664 (2025). [連結](#)
- [R9] Akinseloyin O, Jiang X, Palade V. Large language model-based multiagent collaboration for abstract screening in systematic reviews. Biology Methods & Protocols 11(1):bpag006 (2026). [連結](#)
- [R10] Yamoah K, et al. Fine-Tuning A Large Language Model for Systematic Review Screening. arXiv:2603.24767 (2026). [連結](#)
- [R11] Gartlehner G, et al. Single-reviewer abstract screening missed 13 percent of relevant studies: a crowd-based randomized controlled trial. J Clin Epidemiol 121:20-28 (2020). [連結](#)
- [R12] Nama N, et al. Successful incorporation of single reviewer assessments during systematic review screening: development and validation of an algorithm that considers exclusion criteria and count. Systematic Reviews 10:134 (2021). [連結](#)
- [R13] Noel-Storr AH, et al. Citation screening using crowdsourcing and machine learning produced accurate results: Evaluation of Cochrane's modified Screen4Me service. J Clin Epidemiol 129:41-51 (2021). [連結](#)
- [R14] Pham B, et al. Text mining to support abstract screening for knowledge syntheses: a semi-automated workflow. Systematic Reviews 10:156 (2021). [連結](#)
- [R15] Shemilt I, et al. Machine learning reduced workload for the Cochrane COVID-19 Study Register: development and evaluation of the Cochrane COVID-19 Study Classifier. Systematic Reviews 11:15 (2022). [連結](#)
- [R16] de Bruin J, et al. ASReview LAB v.2: Open-source text screening with multiple agents and a crowd of experts. Patterns (2025). [連結](#)
- [R17] NLP_PRISMA_Reviews: single-reviewer experiment template (GPT-5.4 baseline). [連結](#)
- [R18] NLP_PRISMA_Reviews runtime prompts (current stage-1/2 settings). [連結](#)
- [R19] NLP_PRISMA_Reviews single-reviewer run manifest and F1 JSON for 2409.13738 (2026-03-22 run). [連結](#)
- [R20] NLP_PRISMA_Reviews current stage-split criteria migration metrics for 2409.13738. [連結](#)
- [R21] NLP_PRISMA_Reviews criteria JSON for 2409.13738. [連結](#)
- [R22] NLP_PRISMA_Reviews criteria JSON for 2307.05527. [連結](#)
- [R23] NLP_PRISMA_Reviews criteria JSON for 2511.13936. [連結](#)
- [R24] NLP_PRISMA_Reviews criteria JSON for 2601.19926. [連結](#)